

TRABAJO FINAL DE MASTER

Plataforma de Analisis Deportivo para Club America

Herramienta de Inteligencia Futbolistica con Datos Opta

Rodrigo Jacobs

Master en Sports Analytics
Junio 2026

GitHub: <https://github.com/rodrigojacobs123/football-analytics-platform>

Indice

1. Contexto del Proyecto
2. Objetivos
3. Metodologia
4. Desarrollo de la Herramienta
5. Analisis Realizado — Metricas Avanzadas
6. Resultados
7. Conclusiones
8. Toma de Decisiones
9. Referencias Tecnicas
10. Anexo — Repositorio y Estructura

SECCION 1

Contexto del Proyecto

El presente Trabajo Final de Master desarrolla una plataforma integral de analisis deportivo para el **Club America** (Liga MX), disenada para transformar datos de eventos Opta en inteligencia futbolistica accionable.

La plataforma procesa un dataset masivo de **47 GB** compuesto por **38,271 archivos** JSON de eventos Opta, cubriendo **22 competiciones** de Norteamerica y CONCACAF con temporadas desde 2010 hasta 2026.

Competiciones cubiertas

- **Mexico:** Liga MX, Copa MX, Supercopa MX
- **CONCACAF:** Champions Cup, Leagues Cup, Gold Cup, Nations League, Clasificatorios al Mundial, U17, U20, Campeones Cup
- **Estados Unidos:** MLS, USL Championship, USL League One, MLS Next Pro, US Open Cup
- **Canada:** Canadian Premier League

La herramienta esta orientada al cuerpo tecnico del club (entrenadores, analistas, direccion deportiva y scouting), proporcionando analisis de partidos, inteligencia tactica, evaluacion de jugadores y preparacion de rivales en una interfaz web interactiva.

SECCION 2

Objetivos

Objetivo principal

Construir una plataforma end-to-end que transforme datos crudos de eventos Opta (JSON) en inteligencia futbolistica accionable, cubriendo todo el ciclo de trabajo analitico: preparacion pre-partido, analisis tactico, revision post-partido, scouting de jugadores y toma de decisiones estrategicas.

Objetivos secundarios

- Desarrollar **metricas avanzadas** mas alla de las estadisticas basicas: xG, xT, xGOT, xDEF, PPDA, field tilt, action value (VAEP)
- Crear **visualizaciones profesionales**: mapas de tiro, heatmaps, redes de pases, formaciones, graficos radar, diagramas de pizza
- Implementar **modelos predictivos** para preparacion de partidos: sistema Elo + Poisson + correccion Dixon-Coles
- Soportar **scouting** con ratings estilo FC (PAC/SHO/PAS/DRI/DEF/PHY) y deteccion de arquetipos de jugador
- Proporcionar **inteligencia tactica**: formaciones, intensidad de pressing, transiciones, jugadas a balon parado

SECCION 3

Metodologia

Stack tecnologico

Tecnologia	Uso
Python 3.9+	Lenguaje principal de desarrollo
Streamlit	Framework web para dashboards interactivos
Pandas / NumPy	Procesamiento y analisis de datos tabulares
Plotly	Graficos interactivos (xG race, barras, scatter)
mplsoccer	Visualizaciones sobre cancha (shot maps, heatmaps, formaciones)
scikit-learn	Modelo de xG (regresion logistica)
ReportLab	Generacion de reportes PDF

Arquitectura de 4 capas

La aplicacion sigue un disenio modular en 4 capas claramente separadas:

- **Capa de Datos** (data/): paths.py, loader.py, event_parser.py — lectura de JSON/CSV con cache TTL de 1 hora via @st.cache_data
- **Capa de Procesamiento** (processing/): 42 modulos de analitica pure-pandas — funciones que reciben DataFrames y devuelven DataFrames/dicts, sin dependencias de Streamlit
- **Capa de Visualizacion** (viz/): 14 modulos — Plotly charts, mplsoccer pitches, componentes HTML con design tokens CSS
- **Capa de Paginas** (pages/): 11 dashboards interactivos registrados explicitamente en app.py via st.navigation

Proceso ETL

El flujo de datos sigue el patron: **JSON Opta crudo** → event_parser.py extrae DataFrames tipados (shots, passes, tackles, etc.) → modulos de processing computan metricas avanzadas → modulos de viz renderizan visualizaciones interactivas. El sistema de cache de Streamlit (TTL=3600s) evita re-parsear los archivos JSON en cada interaccion del usuario.

Escala del proyecto

Metrica	Valor
Lineas de codigo	29,243
Modulos de procesamiento	42
Modulos de visualizacion	14
Dashboards interactivos	11

Competiciones cubiertas	22
Temporadas	12+ (2010-2026)
Tamano del dataset	47 GB / 38,271 archivos

SECCION 4

Desarrollo de la Herramienta

La plataforma cuenta con **11 dashboards interactivos**, cada uno diseñado para cubrir un aspecto específico del análisis futbolístico:

Season Dashboard (Home)

KPI cards con posición en liga, puntos, record W-D-L, diferencia de goles. Tabla de posiciones, tendencias cross-temporada. Filtro de torneo Apertura/Clausura específico para Liga MX.

Pre-Match Analysis

Ratings Elo dinámicos, historial H2H, comparación radar, predicción Poisson con simulación Monte Carlo (100,000 iteraciones) y corrección Dixon-Coles para resultados de marcador bajo.

Post-Match Analysis

Grafico xG race, mapas de tiro, heatmaps, redes de pases, visualización de formaciones con posiciones canónicas y promedio, ratings de partido, timeline de eventos clave, análisis de jugadas a balón parado.

Tactics

Detección de formación via qualifier 130, redes de pases por tiempo, acciones defensivas, pases progresivos, PPDA, field tilt, intensidad de pressing, momentum xT.

Player Scouting

Ratings estilo FC (PAC/SHO/PAS/DRI/DEF/PHY), detección de arquetipos de estilo de juego, leaderboards a nivel liga con filtros por posición.

xG Explorer

Explorador interactivo de mapas de tiro con filtros por equipo, jugador, tipo de disparo y resultado.

Injury Tracker

Inteligencia sintética de lesiones con timeline y análisis de patrones.

Data Sources

Diagnósticos del dataset, conteo de archivos por competición/temporada, documentación del schema Opta.

Manager Profiles

Comparación de entrenadores, huellas tácticas, historial de resultados.

Corner Defense

Inteligencia defensiva en corners, análisis por tipo de entrega (inswing, outswing, short), zonas de peligro.

Player Intelligence

Reportes de arquetipos de jugador, evaluación de amenazas, perfiles detallados con métricas multi-dimensionales.

SECCION 5

Analisis Realizado — Metricas Avanzadas

La plataforma implementa un conjunto extenso de metricas avanzadas que van mas alla de las estadisticas tradicionales del futbol:

xG — Expected Goals (Goles Esperados)

Modelo de regresion logistica entrenado sobre distancia de tiro, angulo, parte del cuerpo y situacion de juego. Calcula la probabilidad de gol para cada disparo. Penaltis usan un xG fijo calibrado (xG_penalty).

xT — Expected Threat (Amenaza Esperada)

Matriz de transicion 12x8 que mide la ganancia de valor territorial. Cada accion (pase, conduccion) se evalua por cuanto incrementa la probabilidad de gol del equipo basandose en la zona de origen y destino.

xGOT — Expected Goals on Target

Calidad de colocacion del disparo usando coordenadas de la porteria (qualifier 103). Mide la dificultad del disparo para el portero independientemente de la posicion del tirador.

xDEF — Defensive Expected Goals Prevented

Mide la contribucion defensiva de cada jugador calculando los goles esperados que previene con sus acciones (tackles, intercepciones, bloqueos, recuperaciones).

PPDA — Passes Per Defensive Action

Metrica de intensidad de pressing: numero de pases que el rival completa por cada accion defensiva (tackle, intercepcion, falta) en su propio tercio. Menor PPDA = pressing mas intenso.

Action Value (inspirado en VAEP)

Framework de valoracion de acciones que estima el impacto de cada evento en la probabilidad de gol, considerando el contexto tactico y la secuencia de juego.

Sistema Elo

Rating dinamico de fuerza de equipo con $K=20$, ventaja local=50 puntos. Se actualiza partido a partido y permite comparar equipos de diferentes ligas en una escala comun.

Prediccion Dixon-Coles

Modelo Poisson mejorado con correccion $\rho=-0.13$ para resultados de marcador bajo (0-0, 1-0, 0-1, 1-1). Simulacion Monte Carlo con 100,000 iteraciones para obtener probabilidades de victoria, empate y derrota.

Player Ratings (Ratings de Jugador)

Sistema de ratings especificos por posicion (GK/DEF/MID/FWD) con umbrales minimos de apariciones (5) y minutos (450). Escala 40-99 con categorias especificas por demarcacion.

Motor de Posiciones Tacticas

Sistema de coordenadas canonicas para 25 posiciones con override por formacion. Modo de posicion promedio calculado desde eventos reales con filtrado de balones parados y blending configurable.

SECCION 6

Resultados

Como ejemplo de aplicacion practica, se presenta el analisis de **Club America en el Clausura 2025-2026** de la Liga MX:

Indicador	Valor
Posicion en liga	#7
Puntos	27
Record (W-D-L)	7-6-6
Diferencia de goles	+3
Goles a favor	26
Goles en contra	23
Partidos jugados	19
Puntos por partido	1.42

Capacidades demostradas

- Procesamiento en tiempo real de la temporada completa de Liga MX con actualizacion automatica al agregar nuevos archivos de partidos
- Preparacion pre-partido con probabilidades de victoria basadas en Elo + Poisson para cada jornada
- Revision tactica post-partido con evaluacion de rendimiento basada en xG, mapas de tiro y redes de pases
- Scouting a nivel liga con leaderboards y comparaciones multi-dimensionales de jugadores
- Analisis de corners y balones parados con zonas de peligro y tipos de entrega

Cobertura de datos

La plataforma procesa exitosamente datos de 22 competiciones diferentes, 12+ temporadas (2010-2026), con un total de 38,271 archivos y 47 GB de datos de eventos Opta. El sistema de cache garantiza tiempos de respuesta rapidos incluso con este volumen de datos.

Conclusiones

La plataforma transforma exitosamente 47 GB de datos crudos de eventos en una herramienta analitica interactiva que cubre el flujo completo de inteligencia futbolistica.

Logros principales

- **42 modulos analiticos** cubriendo cada aspecto del analisis de partidos: desde xG basico hasta valoracion de acciones avanzada
- **Interfaz profesional** con tema oscuro, sistema de design tokens CSS y tematizacion dinamica por club
- **Procesamiento en tiempo real** con sistema de cache de Streamlit que minimiza re-calculos innecesarios
- **Modelos predictivos** que combinan Elo + Poisson + metricas tacticas para prediccion de resultados
- **Arquitectura escalable** que cubre 22 competiciones y 12+ temporadas sin degradacion de rendimiento
- **29,243 lineas de codigo** Python organizadas en una arquitectura modular de 4 capas

Limitaciones y trabajo futuro

- El modelo de xG podria mejorarse con features adicionales como presion defensiva y posicion del portero
- Implementar tracking data (coordenadas de todos los jugadores) cuando este disponible para metricas off-ball
- Agregar exportacion automatica de reportes PDF por partido
- Implementar alertas automaticas para cambios significativos en metricas de rendimiento

SECCION 8

Toma de Decisiones

La plataforma habilita la toma de decisiones basada en datos en multiples areas del club:

Preparacion de partidos

Evaluacion de fuerza del rival via Elo y probabilidades de victoria Poisson. Identificacion de fortalezas y debilidades tacticas del oponente para disenar el plan de partido.

Ajustes tacticos

Analisis de formaciones con deteccion automatica, triggers de pressing (PPDA), patrones de transicion, field tilt y momentum xT para identificar fases del partido donde el equipo pierde control.

Evaluacion de jugadores

Ratings multi-dimensionales con metricas especificas por posicion que permiten evaluar el rendimiento individual mas alla de goles y asistencias: contribucion defensiva, progresion de balon, amenaza territorial.

Scouting y fichajes

Leaderboards a nivel liga con clasificacion de arquetipos que permiten identificar perfiles de jugador compatibles con el sistema de juego del equipo y comparar candidatos.

Estrategia de balon parado

Analisis de corners por tipo de entrega (inswing/outswing/short), zonas de peligro en tiros libres, y evaluacion de la efectividad defensiva en situaciones de balon parado.

SECCION 9

Referencias Tecnicas

- [1] Opta Sports. *Opta Event Data Feed — Technical Specification*. Stats Perform.
- [2] Dixon, M.J. & Coles, S.G. (1997). *Modelling Association Football Scores and Inefficiencies in the Football Betting Market*. Applied Statistics, 46(2), 265-280.
- [3] Singh, K. (2019). *Introducing Expected Threat (xT)*. karun.in/blog.
- [4] Decroos, T. et al. (2019). *Actions Speak Louder than Goals: Valuing Player Actions in Soccer*. KDD 2019. (Framework VAEP)
- [5] Streamlit Inc. *Streamlit Documentation*. streamlit.io/docs.
- [6] mplsoccer. *mplsoccer Documentation*. mplsoccer.readthedocs.io.
- [7] Plotly Technologies Inc. *Plotly Python Documentation*. plotly.com/python.
- [8] Pedregosa, F. et al. (2011). *Scikit-learn: Machine Learning in Python*. JMLR 12, 2825-2830.

Anexo — Repositorio y Estructura

Repositorio GitHub

URL: <https://github.com/rodrigojacobs123/football-analytics-platform>

El repositorio contiene todo el código fuente, los 42 módulos de procesamiento, 14 módulos de visualización, 11 páginas de dashboard, y el dataset completo de 47 GB de datos Opta.

Estructura del proyecto

Directorio	Contenido	Archivos
app.py	Punto de entrada de la aplicación Streamlit	1
config.py	Configuración central (IDs, constantes, colores)	1
nav.py	Registro de navegación de páginas	1
data/	Capa de datos: paths, loader, event_parser, silver_events	6
processing/	42 módulos analíticos pure-pandas	42
viz/	14 módulos de visualización (Plotly, mplsoccer, HTML)	14
pages/	11 dashboards interactivos	11
components/	Componentes reutilizables (sidebar, selectores)	4
.streamlit/	Configuración de tema oscuro (config.toml)	1
testeo_ligas_norteamerica/	Dataset Opta: 22 competiciones, 38,271 archivos	38,271

Instrucciones de ejecución

Requisitos: Python 3.9+, pip

Instalación:

```
pip install -r requirements.txt
```

Ejecución:

```
streamlit run app.py
```

La aplicación se abre automáticamente en <http://localhost:8501>